課程人數預測系統

資料科學導論

期末專題報告

組員 施淳譯|蔡譯嶺|陳亭蓁
組名 ChenPolo

Brief Introduction of Problems

課程選課人數的預測以及課程熱門度的評估對於教育機構而言具有重要意義，能夠幫助優化資源分配並改善課程規劃。我們這次的期末專題以成大的歷年選課數據為基礎，運用數據分析與機器學習技術，實現以下目標：

1.預測113學年第1學期以及第2學期的課程選課人數與剩餘名額
2.評估課程熱門度，並為其分配高、中、低等三個標籤
3.利用歷年課程人數的資訊預測新開課程的選課人數

01

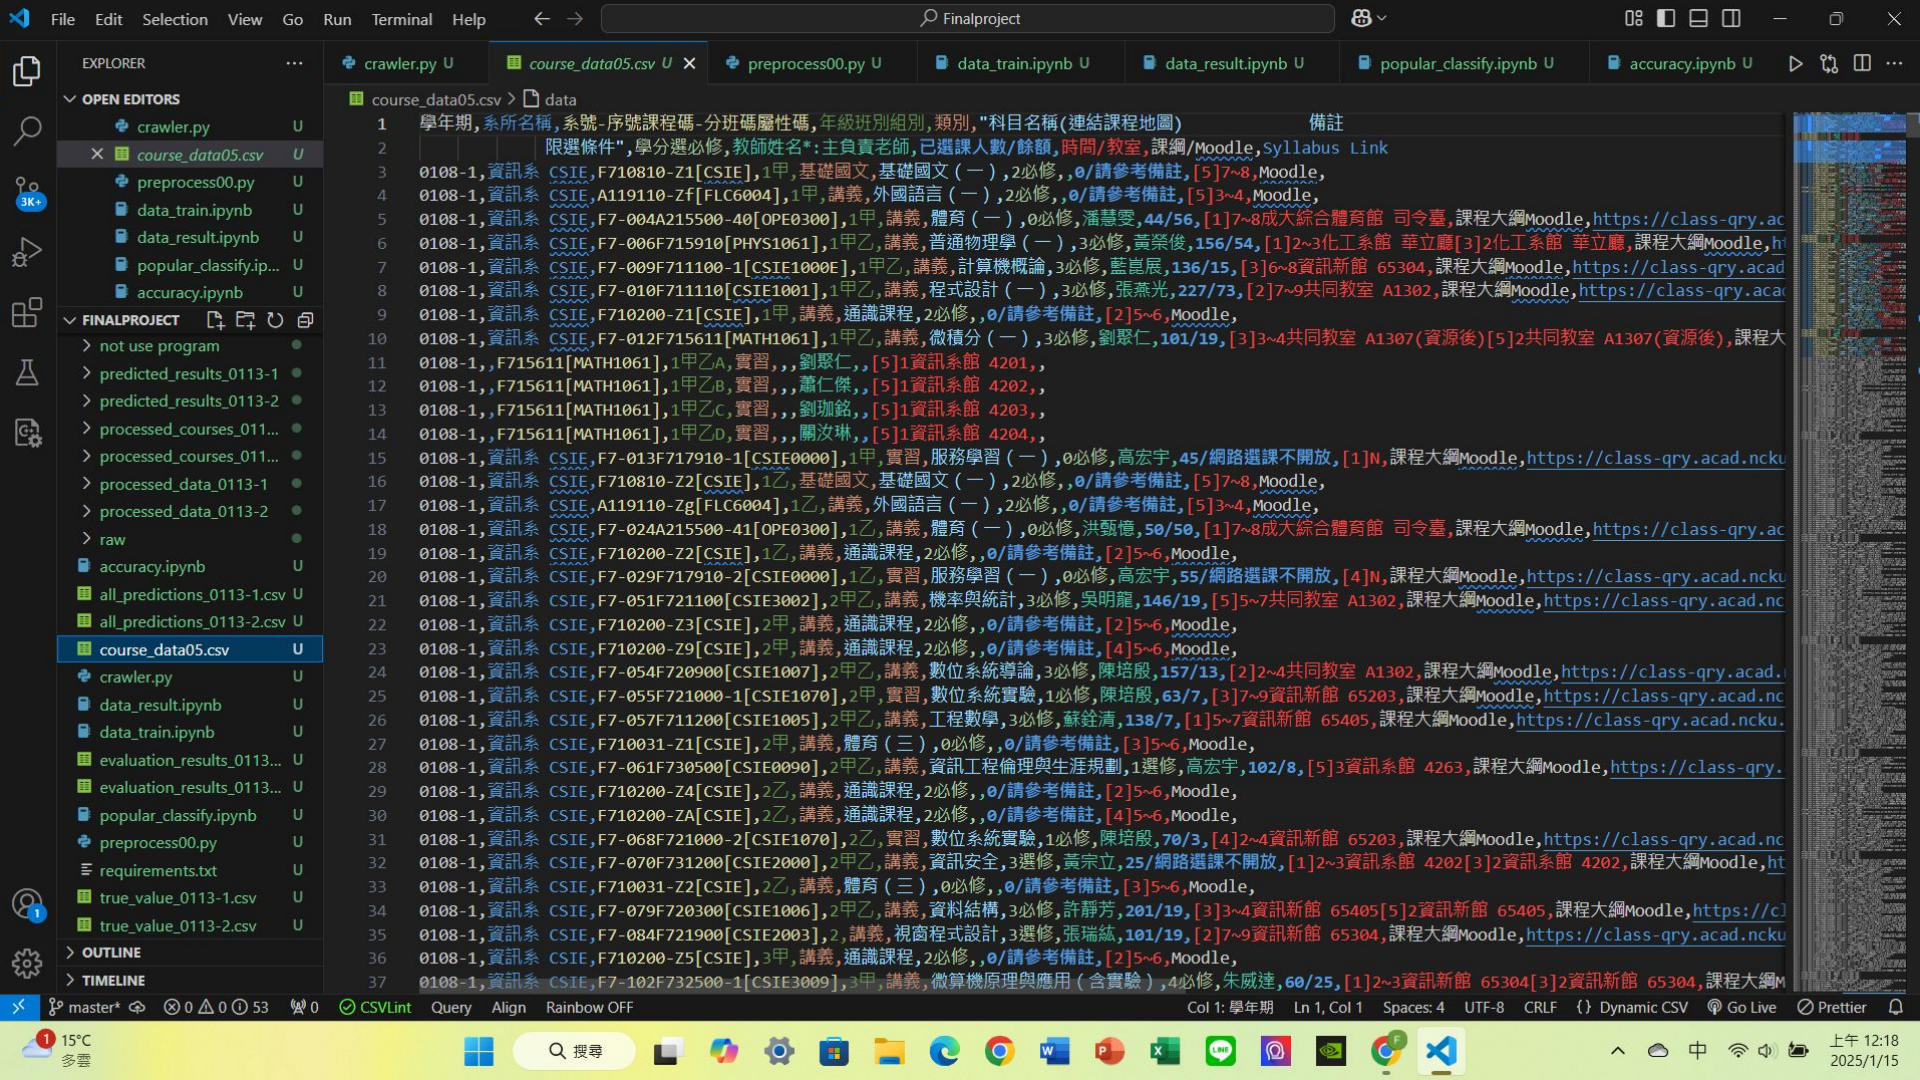
Data Description and Preprocessing



爬取資料:成大歷年選課網站

	學年期	系所名稱	系號-序號課程碼-分班碼屬性碼	年級班別組別	類別	科目名稱(連結課程地圖) 備註 限選條件	學分選必修	教師姓名*:主負責老師	已選課人數/餘額	時間/教
2	0108-2	數學系 MATH	C111820-Z [MATH]	1	基礎國文	基礎國文（二）	2 必修		40/請參考備註	[5]7~8
3	0108-2	數學系 MATH	A119120-Z5 [FLC1001]	1	講義	外國語言（二）	2 必修		0/請參4考備註	[4]3~4
4	0108-2	數學系 MATH	C1-003 C117920 [MATH1102]	1	實習	服務學習（二）	0 必修	林育竹	45/網路選課不開放	[1]N
5	0108-2	數學系 MATH	C1-005 C115621-1 [MATH1123]	1	講義	微積分（二）	4 必修	林育竹	454/16	[1]2~3 理學教學大樓 3 [3]5
6	0108-2		C115621-1 [MATH1123]	1	實習			林育竹	4	[1]1 數學系館 3172
7	0108-2	數學系 MATH	C1-007 C111221 [MATH2103]	1	講義	線性代數（二）	3 必修	劉珈銘	647/13	[3]2 資訊大樓 格致廳小講堂[5]3
8	0108-2		C111221 [MATH2103]	1	實習			劉珈銘	4	[3]1 資訊大樓 格致廳小講堂
9	0108-2	數學系 MATH	C1-009 C115720-1 [PHYS1013]	1	講義	普通物理學（二）	3 必修	游輝樟	54/16	[2]3~4 數學系館 3172[4]2 數學系館 3
10	0108-2	數學系 MATH	C1-010 C111400 [MATH1141]	1	講義	計算機概論與程式語言	3 必修	沈士育	57/13	[3]7~8 數學系館 3172[5]2 數學系館 31
11	0108-2	數學系 MATH	C110020-Z [MATH]	1	講義	體育（二）	0 必修		0/請參考備註	[2]7~8
12	0108-2	數學系 MATH	C125000-Z1 [MATH]	1	講義	通識課程	2 必修		0/請參考4備註	[3]3~4
13	0108-2	數學系 MATH	C125000-Z2 [MATH]	2	講義	通識課程	2 必修		0/請參考備註	[1]7~8
14	0108-2	數學系 MATH	C110040-Z [MATH]	2	講義	體育（四）	0 必修		0/請參考備註	[2]5~6
15	0108-2	數學系 MATH	C1-055 C121121-1 [MATH2122]	2	講義	高等微積分（二）	4 必修	劉育佑	42/8	[1]5~6 數學系館 3172[3]3~4 數學系館
16	0108-2		C121121-1 [MATH2122]	2	實習			劉育佑	4	[1]N 數學系館 3172
17	0108-2	數學系 MATH	C1-056 C121121-2 [MATH2122]	2	講義	高等微積分（二）	4 必修	陳若淳	35/145	[1]5~6 數學系館 3174[3]3~4 數學系館
18	0108-2		C121121-2 [MATH2122]	2	實習			陳若淳		[1]N 數學系館 3174
19	0108-2	數學系 MATH	C1-057 C121311 [MATH2143]	2	講義	代數學（一）	3 必修	章源慶	654/25	[2]3~4 理學教學大樓 36202[4]2 理學教
20	0108-2		C121311 [MATH2143]	2	實習			章源慶		[4]1 理學教學大樓 36202
21	0108-2	數學系 MATH	C1-058 C120501 [MATH2133]	2	講義	微分方程導論	3 必修	李國明	446/24	[2]2 共同教室 A1306(資源後)[4]3~4 共
22	0108-2		C120501 [MATH2133]	2	實習			李國明	4	[2]1 共同教室 A1306(資源後)
23	010	數學系 MATH	C125000-Z5 [MATH]	2	講義	通識課程	2 必修		0/依照該類課程科目序4號選課	[4]7~8
24	0108-2									
25	010									73[4]6 數學系館 31
26	0108-2									[5]5~6 數學系館 31
27	0108	數學系 MATH	C1-104 C133800 [MATH5202]	3	講義	複變數函數論	3 選修	陳若淳	49/1	[3]2 數學系館 3174[5]3~4 數學系館 31
28	0108-2	數學系 MATH	C1-106 C147400 [MATH3603]	3	講義	統計推論	3 選修	黃郁芬	29/6	[2]7~8 數學系館 3173[3]N 數學系館 31
29	0108-2	數學系 MATH	C1-107 C137500 [MATH3708]	3	講義	數據科學裡的矩陣方法	3 選修	王辰樹	18/17	[1]8 數學系館 3175[4]5~6 數學系館 31

爬取資料:成大歷年選課網站


File Edit Selection View Go Run Terminal Help
Finalproject
EXPLORER
OPEN EDITORS
crawler.py U
course_data05.csv U
preprocess00.py U
data_train.ipynb U
data_result.ipynb U
popular_classify.ip... U
accuracy.ipynb U
FINALPROJECT
not use program
predicted_results_0113-1
predicted_results_0113-2
processed_courses_011...
processed_courses_011...
processed_data_0113-1
processed_data_0113-2
raw
accuracy.ipynb U
all_predictions_0113-1.csv U
all_predictions_0113-2.csv U
course_data05.csv U
crawler.py U
data_result.ipynb U
data_train.ipynb U
evaluation_results_0113... U
evaluation_results_0113... U
popular_classify.ipynb U
preprocess00.py U
requirements.txt U
true_value_0113-1.csv U
true_value_0113-2.csv U
OUTLINE
TIMELINE
crawler.py U
course_data05.csv U
preprocess00.py U
data_train.ipynb U
data_result.ipynb U
popular_classify.ipynb U
accuracy.ipynb U
course_data05.csv > data
學年期,系所名稱,系號-序號課程碼-分班碼屬性碼,年級班別組別,類別,"科目名稱(連結課程地圖) 備註
限選條件",學分選必修,教師姓名*:主負責老師,已選課人數/餘額,時間/教室,課綱/Moodle,Syllabus Link
0108-1,資訊系 CSIE,F710810-Z1[CSIE],1甲,基礎國文,基礎國文（一）,2必修,,0/請參考備註,[5]7~8,Moodle,
0108-1,資訊系 CSIE,A119110-Zf[FLC6004],1甲,講義,外國語言（一）,2必修,,0/請參考備註,[5]3~4,Moodle,
0108-1,資訊系 CSIE,F7-004A215500-40[OPE0300],1甲,講義,體育（一）,0必修,潘慧雯,44/56,[1]7~8成大綜合體育館 司令臺,課程大綱Moodle,https://class-qry.ac
0108-1,資訊系 CSIE,F7-006F715910[PHYS1061],1甲乙,講義,普通物理學（一）,3必修,黃榮俊,156/54,[1]2~3化工系館 華立廳[3]2化工系館 華立廳,課程大綱Moodle,ht
0108-1,資訊系 CSIE,F7-009F711100-1[CSIE1000E],1甲乙,講義,計算機概論,3必修,藍崑展,136/15,[3]6~8資訊新館 65304,課程大綱Moodle,https://class-qry.acad
0108-1,資訊系 CSIE,F7-010F711110[CSIE1001],1甲乙,講義,程式設計（一）,3必修,張燕光,227/73,[2]7~9共同教室 A1302,課程大綱Moodle,https://class-qry.aca
0108-1,資訊系 CSIE,F710200-Z1[CSIE],1甲,講義,通識課程,2必修,,0/請參考備註,[2]5~6,Moodle,
0108-1,資訊系 CSIE,F7-012F715611[MATH1061],1甲乙,講義,微積分（一）,3必修,劉聚仁,101/19,[3]3~4共同教室 A1307(資源後)[5]2共同教室 A1307(資源後),課程大
0108-1,,F715611[MATH1061],1甲乙A,實習,,劉聚仁,,[5]1資訊系館 4201,,
0108-1,,F715611[MATH1061],1甲乙B,實習,,蕭仁傑,,[5]1資訊系館 4202,,
0108-1,,F715611[MATH1061],1甲乙C,實習,,劉珈銘,,[5]1資訊系館 4203,,
0108-1,,F715611[MATH1061],1甲乙D,實習,,關汝琳,,[5]1資訊系館 4204,,
0108-1,資訊系 CSIE,F7-013F717910-1[CSIE0000],1甲,實習,服務學習（一）,0必修,高宏宇,45/網路選課不開放,[1]N,課程大綱Moodle,https://class-qry.acad.ncku
0108-1,資訊系 CSIE,F710810-Z2[CSIE],1乙,基礎國文,基礎國文（一）,2必修,,0/請參考備註,[5]7~8,Moodle,
0108-1,資訊系 CSIE,A119110-Zg[FLC6004],1乙,講義,外國語言（一）,2必修,,0/請參考備註,[5]3~4,Moodle,
0108-1,資訊系 CSIE,F7-024A215500-41[OPE0300],1乙,講義,體育（一）,0必修,洪甄憶,50/50,[1]7~8成大綜合體育館 司令臺,課程大綱Moodle,https://class-qry.ac
0108-1,資訊系 CSIE,F710200-Z2[CSIE],1乙,講義,通識課程,2必修,,0/請參考備註,[2]5~6,Moodle,
0108-1,資訊系 CSIE,F7-029F717910-2[CSIE0000],1乙,實習,服務學習（一）,0必修,高宏宇,55/網路選課不開放,[4]N,課程大綱Moodle,https://class-qry.acad.ncku
0108-1,資訊系 CSIE,F7-051F721100[CSIE3002],2甲乙,講義,機率與統計,3必修,吳明龍,146/19,[5]5~7共同教室 A1302,課程大綱Moodle,https://class-qry.acad.nc
0108-1,資訊系 CSIE,F710200-Z3[CSIE],2甲,講義,通識課程,2必修,,0/請參考備註,[2]5~6,Moodle,
0108-1,資訊系 CSIE,F710200-Z9[CSIE],2甲,講義,通識課程,2必修,,0/請參考備註,[4]5~6,Moodle,
0108-1,資訊系 CSIE,F7-054F720900[CSIE1007],2甲乙,講義,數位系統導論,3必修,陳培殷,157/13,[2]2~4共同教室 A1302,課程大綱Moodle,https://class-qry.acad.
0108-1,資訊系 CSIE,F7-055F721000-1[CSIE1070],2甲,實習,數位系統實驗,1必修,陳培殷,63/7,[3]7~9資訊新館 65203,課程大綱Moodle,https://class-qry.acad.nc
0108-1,資訊系 CSIE,F7-057F711200[CSIE1005],2甲乙,講義,工程數學,3必修,蘇銓清,138/7,[1]5~7資訊新館 65405,課程大綱Moodle,https://class-qry.acad.ncku.
0108-1,資訊系 CSIE,F710031-Z1[CSIE],2甲,講義,體育（三）,0必修,,0/請參考備註,[3]5~6,Moodle,
0108-1,資訊系 CSIE,F7-061F730500[CSIE0090],2甲乙,講義,資訊工程倫理與生涯規劃,1選修,高宏宇,102/8,[5]3資訊系館 4263,課程大綱Moodle,https://class-qry.
0108-1,資訊系 CSIE,F710200-Z4[CSIE],2乙,講義,通識課程,2必修,,0/請參考備註,[2]5~6,Moodle,
0108-1,資訊系 CSIE,F710200-ZA[CSIE],2乙,講義,通識課程,2必修,,0/請參考備註,[4]5~6,Moodle,
0108-1,資訊系 CSIE,F7-068F721000-2[CSIE1070],2乙,實習,數位系統實驗,1必修,陳培殷,70/3,[4]2~4資訊新館 65203,課程大綱Moodle,https://class-qry.acad.nc
0108-1,資訊系 CSIE,F7-070F731200[CSIE2000],2甲乙,講義,資訊安全,3選修,黃宗立,25/網路選課不開放,[1]2~3資訊系館 4202[3]2資訊系館 4202,課程大綱Moodle,ht
0108-1,資訊系 CSIE,F710031-Z2[CSIE],2乙,講義,體育（三）,0必修,,0/請參考備註,[3]5~6,Moodle,
0108-1,資訊系 CSIE,F7-079F720300[CSIE1006],2甲乙,講義,資料結構,3必修,許靜芳,201/19,[3]3~4資訊新館 65405[5]2資訊新館 65405,課程大綱Moodle,https://cl
0108-1,資訊系 CSIE,F7-084F721900[CSIE2003],2,講義,視窗程式設計,3選修,張瑞紘,101/19,[2]7~9資訊新館 65304,課程大綱Moodle,https://class-qry.acad.ncku
0108-1,資訊系 CSIE,F710200-Z5[CSIE],3甲,講義,通識課程,2必修,,0/請參考備註,[2]5~6,Moodle,
0108-1,資訊系 CSIE,F7-102F732500-1[CSIE3009],3甲,講義,微算機原理與應用（含實驗）,4必修,朱威達,60/25,[1]2~3資訊新館 65304[3]2資訊新館 65304,課程大綱M
master* 0 0 0 53 0 CSVLint Query Align Rainbow OFF
Col 1: 學年期 Ln 1, Col 1 Spaces: 4 UTF-8 CRLF {} Dynamic CSV Go Live Prettier
15°C 多雲
搜尋
中
上午 12:18 2025/1/15

```python
INPUT_CSV = 'course_data05.csv'
YEAR_FILTER = '0113-1'  # 修改為你想篩選的年份
OUTPUT_FOLDER = f'processed_data_{YEAR_FILTER}/'

if __name__ == '__main__':
    split_by_department_and_year(INPUT_CSV, OUTPUT_FOLDER, YEAR_FILTER)
```




```
學年期,系所名稱,系號-序號課程碼-分班碼屬性碼,年級班別組別,類別,"科目名稱(連結
                限選條件",學分選必修,教師姓名*:主負責老師,已選課人數/餘額,時間
0113-1,數學系 MATH,C1-004C115611-1[MATH1113],1,講義,微積分（一）,4必修,劉
0113-1,數學系 MATH,C1-006C111300-1[MATH1131],1,講義,數學導論,3必修,劉之中
0113-1,數學系 MATH,C1-008C315710[PHYS1011],1,講義,普通物理學（一）,3必修,
0113-1,數學系 MATH,C1-009C111211-1[MATH1163],1,講義,線性代數（一）,3必修,
0113-1,數學系 MATH,C1-051C121111-1[MATH2113],2,講義,高等微積分（一）,4必
0113-1,數學系 MATH,C1-053C121311[MATH2143],2,講義,代數學（一）,3必修,林牛
0113-1,數學系 MATH,C1-054C120601-1[MATH3202],2,講義,機率導論,3必修,劉聚仁
0113-1,數學系 MATH,C1-055C122100[MATH1152],2,講義,數論導論,3選修,林牛,42,
```

```
學年期,系所名稱,系號-序號課程碼-分班碼屬性碼,年級班別組別,類別,"科目名稱(連結課程地圖
                限選條件",學分選必修,教師姓名*:主負責老師,已選課人數/餘額,時間/教室,課
0108-1,數學系 MATH,C1-004C115611-1[MATH1113],1,講義,微積分（一）,4必修,林育竹,53/
0108-1,數學系 MATH,C1-006C111300-1[MATH1131],1,講義,數學導論,3必修,連文璟,55/17,[
0108-1,數學系 MATH,C1-008C115710[PHYS1011],1,講義,普通物理學（一）,3必修,游輝樟,54
0108-1,數學系 MATH,C1-009C111211[MATH1163],1,講義,線性代數（一）,3必修,劉珈銘,62/
0108-1,數學系 MATH,C1-051C111221-1[MATH2103],2,講義,線性代數（二）,3必修,林牛,26/
0108-1,數學系 MATH,C1-052C121111-1[MATH2113],2,講義,高等微積分（一）,4必修,劉育佑,
0108-1,數學系 MATH,C1-053C121111-2[MATH2113],2,講義,高等微積分（一）,4必修,陳若淳,
0108-1,數學系 MATH,C1-054C120601-1[MATH3202],2,講義,機率導論,3必修,劉聚仁,64/6,[2
0108-1,數學系 MATH,C1-055C122500[MATH2214],2,講義,科學計算軟體,3選修,陳旻宏,36/14
```

02

Insight discovered from data

You can enter a subtitle here if you need it

1) 課程需求與餘額的相關性

a) 大部分課程的餘額人數與課程容量(總人數)呈現正相關

b) 有部分課程隨著選課人數的增加，餘額人數反而沒有增加，可以推測是因為課程受歡迎程度直接影響

2) 課程的學年期數據分布

a) 課程紀錄的數量差異

b) 學年期趨勢分析

3) 數值清理與處理中的發現

a) 缺失值的處理

b) 數據異常

03

Popularity Prediction

Modeling and Predicting

1) 方法一

- 使用課程的歷史“選課人數”、“餘額”和“學年期”作為核心輸入變量
- 賦予近期學年數據更高的權重
- Ensemble learning方法運行5個隨機森林模型
- 0.2 train test validation
- 對於所有資料筆數大於二的課程, 進行預測

Modeling and Predicting

2) 方法二:

- 對於113-1以及113-2兩個學期所開設的課程進行預測
- 對於其他資料, 查詢對應相同課程名稱的課程的歷年開課資料
- 使用加權平均來預測選課人數
- 依照開設的學期遠近以降冪排列, 並給予次序(order)
- 標準化權重, 越近的學期有更高的權重
- 扣除掉要預測的學期的課程資料, 選擇資料筆數>2的課程進行預測

Modeling and Predicting

2) 方法三:

- 使用RandomForestRegression對於除了要預測學期外的所有資料, 學習資料特徵
- 其中對於課程類別(講義/實習)、分班、必選修以及授課教師等等類別欄位, 進行OneHotEncoding
- 對於學分數、開課年級直接使用數值型資料
- 對於學年級與方法二中類似, 對於開課學年依照年份進行ranking
- 使用Bagging方式集成10個RandomForestRegression來進行預測

Popularity Classification

1) 熱門度計算與分類標準

   熱門度的定義:已選課人數/ (已選課人數＋餘額)

   分類標準:

   a) 高熱門度:熱門度高於75百分位數

   b) 中熱門度:熱門度介於25百分位數與75百分位數之間

   c) 低熱門度:熱門度低於25百分位數

Popularity Classification

2) 熱門度的分類方式:
   - 基於分位數
   - 基於optuna優化

```python
# 定義 1：已選課人數比例
popularity_ratio = df['預測選課'] / (df['預測選課'] + df['預測餘額'])

# 定義 2：餘額反向
popularity_balance = 1 / (1 + df['預測餘額'])

# 使用加權公式計算總熱門度
popularity_score = weight * popularity_ratio + (1 - weight) * popularity_balance
```

```python
def objective(trial, df):
    """Optuna 的目標函式"""
    # 生成權重參數
    weight = trial.suggest_float("weight", 0, 1)

    # 計算熱門度
    df['熱門度'] = calculate_popularity(df, weight)

    # 模擬目標排名（假設真實熱門度以 '已選課人數' 排序）
    df['實際排名'] = df['預測選課'].rank(ascending=False)
    df['預測排名'] = df['熱門度'].rank(ascending=False)

    # 計算排名差異（均方誤差）
    rank_diff = np.mean((df['實際排名'] - df['預測排名']) ** 2)

    return rank_diff
```

Popularity Classification

方法一

基於分位數

```
高閾值（75%）: 0.9509151069570843
低閾值（25%）: 0.5759251632376665
```

基於Optuna優化

```
高閾值：0.7758071695951341
低閾值：0.25506712796934 81
```

Popularity Classification

方法二

113-1 基於分位數

```
高閾值 (75%): 0.7510458682792724
低閾值 (25%): 0.5828630190514208
```

113-1 基於 Optuna優化

```
最佳分位數參數：{'high_quantile': 0.7521523107491883, 'low_quantile': 0.23912201409178624}
```

113-2基於分位數

```
高閾值 (75%): 0.5637739953793063
低閾值 (25%): 0.422150470266092
```

113-2 基於 Optuna優化

```
最佳分位數參數：{'high_quantile': 0.7329512601995584, 'low_quantile': 0.26410977625110454}
```

Popularity Classification

方法三

113-1 基於分位數

```
高閾值 (75%): 0.7652285292080925
低閾值 (25%): 0.5964611187657578
```

113-1 基於 Optuna優化

```
最佳分位數參數：{'high_quantile': 0.7697078149230706, 'low_quantile': 0.2530871768548616}
```

113-2基於分位數

```
高閾值 (75%): 0.8553051170095382
低閾值 (25%): 0.726347377497896
```

113-2 基於 Optuna優化

```
最佳分位數參數：{'high_quantile': 0.7491216781963691, 'low_quantile': 0.24057697223589733}
```

Evaluation and Results

1) 結果與評估評估指標
   a) 回歸評估指標
      - 使用MSE以及MAE進行評估
   b) 分類評估指標
      - 使用混淆矩陣評估熱門課程分類的準確性
      - 使用Accuracy, Recall 和 F1分數進行分析

Evaluation and Results

1) 基於**方法一**的評估:

   a) 回歸評估指標:

```
回歸模型評估：
均方誤差 (MSE): 58.28
平均絕對誤差 (MAE): 6.20
```

   b) 分類評估指標:

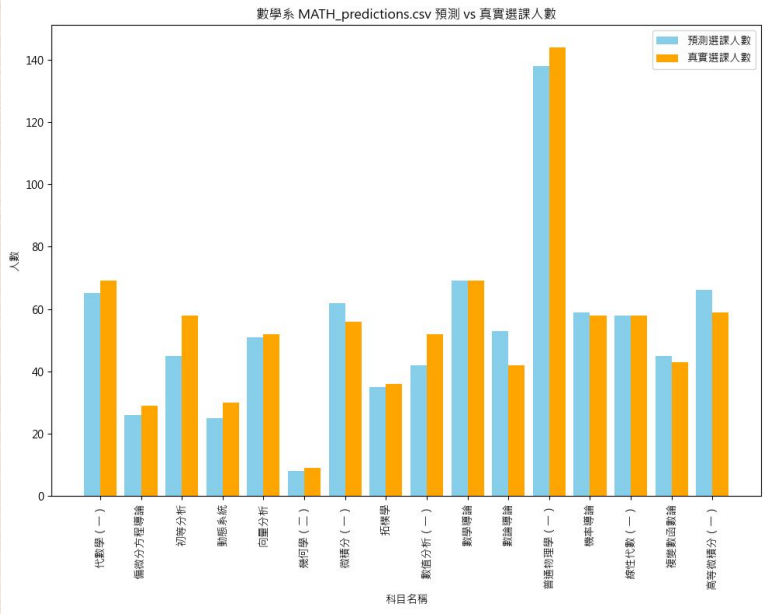
```
熱門度分類評估：
混淆矩陣：
[[ 56   0   0]
 [  0 110   0]
 [  0   0  56]]
準確率 (Accuracy): 1.00
召回率 (Recall): 1.00
F1 分數: 1.00
```

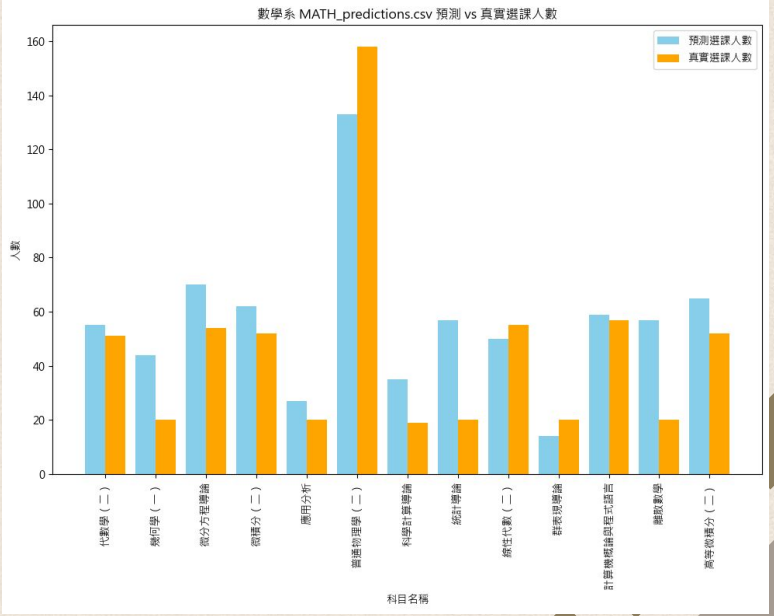
```
(array([[ 56,   0,   0],
        [  0, 110,   0],
        [  0,   0,  56]]),
 1.0,
 1.0,
 1.0)
```

Evaluation and Results

2) 基於**方法二**的評估:

a) 預測選課人數與真實選課人數對照113-1(左) 113-2(右)





Evaluation and Results

2) 基於**方法二**的評估:

a) 回歸評估指標:113-1(左)、113-2(右)

```
回歸模型評估：
均方誤差 (MSE): 478.75
平均絕對誤差 (MAE): 12.09
```

```
回歸模型評估：
均方誤差 (MSE): 589.17
平均絕對誤差 (MAE): 17.76
```

b) 分類評估指標:113-1(左)、113-2(右)

```
熱門度分類評估：
混淆矩陣：
[[21  3  2]
 [ 4 33  6]
 [ 0  8 16]]
準確率 (Accuracy): 0.75
召回率 (Recall): 0.75
F1 分數: 0.75
```

```
(array([[21,  3,  2],
        [ 4, 33,  6],
        [ 0,  8, 16]], dtype=int64),
 0.7526881720430108,
 0.7526881720430108,
 0.7530371436672555)
```

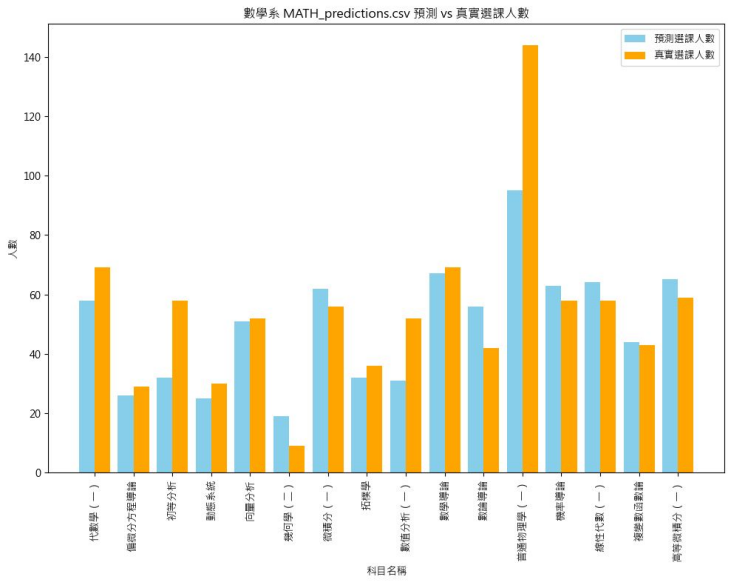
```
熱門度分類評估：
混淆矩陣：
[[ 9 12  8]
 [ 8 13  3]
 [ 1  9  8]]
準確率 (Accuracy): 0.42
召回率 (Recall): 0.42
F1 分數: 0.42
```

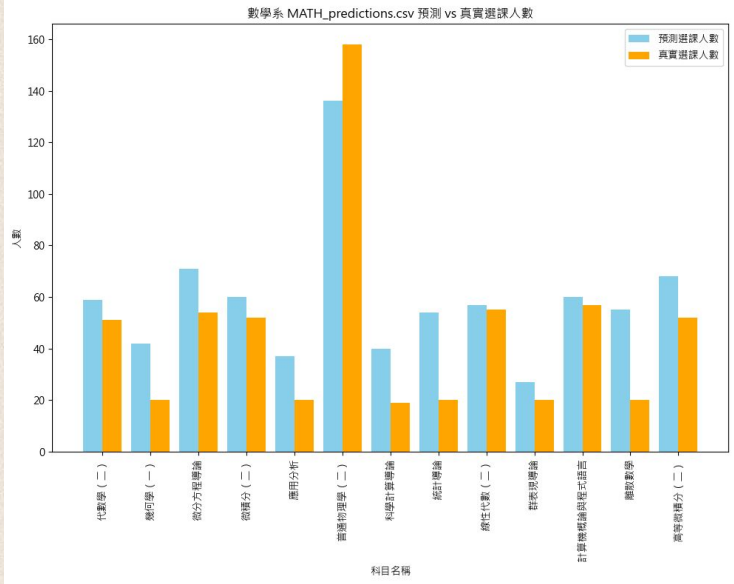
```
(array([[ 9, 12,  8],
        [ 8, 13,  3],
        [ 1,  9,  8]], dtype=int64),
 0.4225352112676056,
 0.4225352112676056,
 0.4175885556642586)
```

Evaluation and Results

2) 基於**方法三**的評估:

a) 預測選課人數與真實選課人數對照113-1(左) 113-2(右)





Evaluation and Results

2) 基於**方法三**的評估:

a) 回歸評估指標:113-1(左)、113-2(右)

```
回歸模型評估：
均方誤差 (MSE): 977.15
平均絕對誤差 (MAE): 21.45
```

```
回歸模型評估：
均方誤差 (MSE): 909.80
平均絕對誤差 (MAE): 19.55
```

b) 分類評估指標:113-1(左)、113-2(右)

```
混淆矩陣：
[[19  7  4]
 [ 5 29 11]
 [ 0 14 12]]
準確率 (Accuracy): 0.59
召回率 (Recall): 0.59
F1 分數: 0.60
```

```
(array([[19,  7,  4],
        [ 5, 29, 11],
        [ 0, 14, 12]], dtype=int64),
 0.594059405940594,
 0.594059405940594,
 0.5976077250227506)
```

```
混淆矩陣：
[[ 8 16  8]
 [10 11  2]
 [ 3  7  9]]
準確率 (Accuracy): 0.38
召回率 (Recall): 0.38
F1 分數: 0.37
```

```
(array([[ 8, 16,  8],
        [10, 11,  2],
        [ 3,  7,  9]], dtype=int64),
 0.3783783783783784,
 0.3783783783783784,
 0.37212932893171224)
```

```python
# 讀取已清理的資料
file_path = 'cleaned_course_data.csv'
data = pd.read_csv(file_path)

# 優化後的關鍵字與細分類特徵映射
keywords = {…

# 初始化特徵
def initialize_features(data, keywords):
    for feature in keywords.keys():
        if feature not in data.columns:
            data[feature] = False
    return data

# 初始化數據
data = initialize_features(data, keywords)

# 根據系別分類課程
departments = {
    "數學系": data[data['系所名稱'].str.contains('數學', na=False)],
    "統計系": data[data['系所名稱'].str.contains('統計', na=False)],
    "資訊系": data[data['系所名稱'].str.contains('資訊', na=False)],
    "測量系": data[data['系所名稱'].str.contains('測量', na=False)]
}

# 保存進度檔案
progress_file = 'progress_math.json'

# 加載進度
if os.path.exists(progress_file):
    with open(progress_file, 'r') as f:
        progress = json.load(f)
else:
    progress = {}
```

手動勾選，將課程名稱分解成不同課程特徵

3-2-1 預測新開課程選課狀況模型-方法



[128]:
```
# 讀取數據
course_data = pd.read_csv("enhanced_math_course_data.csv")

# 移除特定課名的列
excluded_courses = ["體育(一)","體育(二)", "服務學習(一)", "服務學習(二)"]
course_data = course_data[~course_data['科目名稱(連結課程地圖)              備註 \n              限選條件'].isin(excluded_courses)]
```

[129]:
```
course_data = course_data.drop(['系所名稱', '學分', '時間', '教室'], axis=1)
# 僅對布林值和特定欄位進行替換
course_data['必選修'] = course_data['必選修'].replace({'必修': 0, '選修': 1, '必選': 2})
course_data = course_data.replace({True: 1, False: 0})
# 修正欄位名稱，去除空格和特殊字符
course_data.columns = course_data.columns.str.strip()
# 分離 "已選課人數" 和 "餘額"
course_data[['已選課人數', '餘額']] = course_data['已選課人數/餘額'].str.split('/', expand=True)
# 移除 '餘額' 列中值為 "網路選課不開放" 的行
course_data = course_data[course_data['餘額'] != '網路選課不開放']
# 處理 "餘額" 中的特殊值
course_data['餘額'] = course_data['餘額'].replace(['額滿'], 0)
# 將 "餘額" 列轉換為整數，非數字的值替換為 NaN 並填充為 0
course_data['餘額'] = pd.to_numeric(course_data['餘額'], errors='coerce').fillna(0).astype(int)
# 將 "已選課人數" 轉換為整數
course_data['已選課人數'] = pd.to_numeric(course_data['已選課人數'], errors='coerce').fillna(0).astype(int)
# 確保 '餘額' 列的類型為整數
course_data['餘額'] = pd.to_numeric(course_data['餘額'], errors='coerce').fillna(0).astype(int)
print(course_data.columns)
```

3-2-2 預測選課人數模型-數據預處理

[130]:
```
course_data
```

[130]:

	學年期	科目名稱(連結課程地圖) 備註 \n限選條件	教師姓名*:主負責老師	已選課人數/餘額	系所名稱_label	必選修	類別_實習	類別_講義	數學_微積分	數學_ODE	...	測量_攝影測量	統計_迴歸分析	統計_抽樣方法	統計_多變量分析	統計_類別資料分析	統計_工業應用	統計_統計推論	跨領域	已選課人數	餘額
0	0108-2	微積分 (二)	林育竹	54/16	0	0	0	1	1	0	...	0	0	0	0	0	0	0	0	54	16
1	0108-2	線性代數 (二)	劉珈銘	67/13	0	0	0	1	0	0	...	0	0	0	0	0	0	0	0	67	13
2	0108-2	普通物理學 (二)	游輝樟	54/16	0	0	0	1	0	0	...	0	0	0	0	0	0	0	1	54	16
3	0108-2	計算機概論與程式語言	沈士育	57/13	0	0	0	1	0	0	...	0	0	0	0	0	0	0	0	57	13
4	0108-2	高等微積分 (二)	劉育佑	42/8	0	0	0	1	1	0	...	0	0	0	0	0	0	0	0	42	8
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
883	0113-1	空間資訊整合與應用	朱宏杰	25/3	1	1	0	1	0	0	...	0	0	0	0	0	0	0	0	25	3
884	0113-1	水土保持工程	倪勝火	93/5	1	1	0	1	0	0	...	0	0	0	0	0	0	0	1	93	5
885	0113-1	工程實務 - 世曦論壇	廖學瑞	132/68	1	1	0	1	0	0	...	0	0	0	0	0	0	0	1	132	68

```python
# 2. 預處理數據

# 確保 "已選課人數" 列中沒有零，避免零除錯誤
course_data['已選課人數'] = course_data['已選課人數'].replace(0, 1)

# 新增 "餘額/已選課人數" 特徵
course_data['餘額_已選課人數比'] = course_data['已選課人數'] / (course_data['已選課人數'] + course_data['餘額']) * 100

# 特徵選擇（去除無關欄位）
X = course_data.drop
(['學年期','已選課人數/餘額','已選課人數','餘額','餘額_已選課人數比','類別_講義','科目名稱(連結課程地圖)備註 \n限選條件','教師姓名*:主負責老師'], axis=1)
y = course_data['餘額_已選課人數比']

# 分割訓練集和測試集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# 3. 建立和訓練模型
rf_model = RandomForestRegressor(random_state=42, n_estimators=100)
rf_model.fit(X_train, y_train)

# 4. 預測和評估
y_pred = rf_model.predict(X_test)
mse = mean_squared_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print(f"Mean Squared Error: {mse}")
print(f"R^2 Score: {r2}")
```

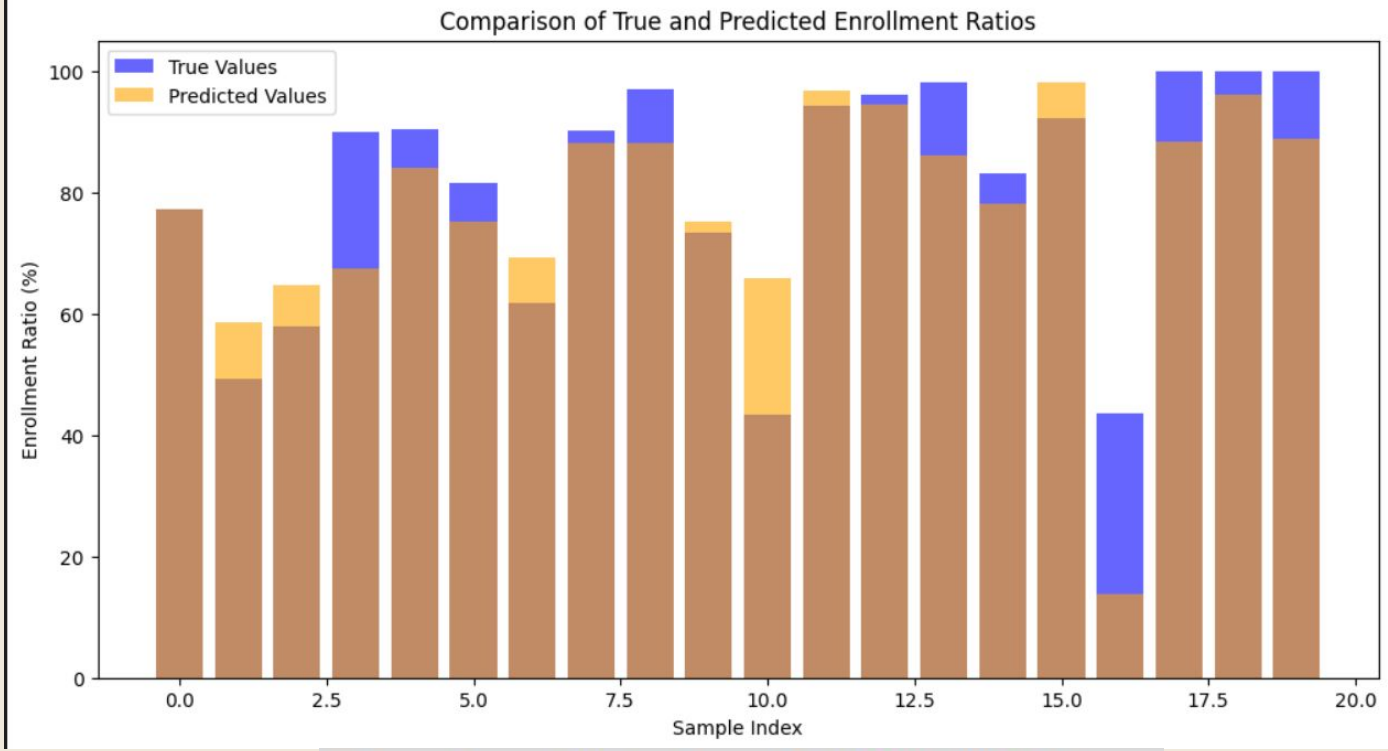
新增特徵、切割資料集並訓練

```python
import joblib

# 保存模型到檔案
joblib.dump(rf_model, 'rf_model.pkl')
print("模型已保存到 'rf_model.pkl'")
```

```
模型已保存到 'rf_model.pkl'
```

保存模型




```
Mean Squared Error: 324.5084839786421
R^2 Score: 0.27554750540793316
```

3-2-4 預測選課人數模型-評估與分析

04

Demo

You can enter a subtitle here if you need it

05

Conclusions and Novelty

You can enter a subtitle here if you need it

Conclusion

在這次的專題中，我們透過課程的歷史數據分別使用不同的方式對113-1以及113-2開設的課程進行預測、評估其準確度以及對課程的熱門度進行分類

1) 課程預測:
   - 我們觀察到在方法二、三在113-1中的表現明顯比較好
   - 追蹤各階段的選課情形，精進我們模型的預測能力
   - 方案三結果並不如我們的預期
   - 增加更多的特徵、改進評估的方式、對資料進行處理與校正

Conclusion

2) 熱門度分類:

- 熱門度分類在方法二以及方法三中都沒有很好
- 改進我們的預測結果
- 重新評估熱門度的評估指標

各科系的熱門課程:
資工系(共7堂):資訊專題(一)、資訊專題(二)、資訊工程倫理與生涯規劃、統計學習導論、從創意到創新(二)、Linux 系統與開源軟體、進階英語課程-專業科學英文(一)
測量系(共6堂):土地法及測量法規、普通物理學實驗(一)、普通物理學實驗(二)、航測及遙測基礎、計算機程式設計、科學計算軟體
數學系(共2堂):離散數學、計算機概論與程式語言

Conclusion

統計系:

```
統計系 STAT,實用民商法律入門,高
統計系 STAT,經濟學（二）,高
統計系 STAT,微積分（二）,高
統計系 STAT,抽樣調查,高
統計系 STAT,統計學（二）,高
統計系 STAT,統計軟體與繪圖,高
統計系 STAT,類別資料分析,高
統計系 STAT,多變量分析,高
統計系 STAT,計算機概論,高
統計系 STAT,迴歸分析,高
統計系 STAT,資料處理,高
統計系 STAT,作業研究,高
統計系 STAT,公司治理與財務報導-國際會計與稅務專題研,高
統計系 STAT,實驗設計,高
統計系 STAT,數理統計（二）,高
統計系 STAT,會計學（一）,高
統計系 STAT,機率概論,高
統計系 STAT,數理統計（一）,高
統計系 STAT,無母數統計,高
統計系 STAT,管理學,高
統計系 STAT,統計學（一）,高
統計系 STAT,統計諮詢,高
統計系 STAT,統計資料分析,高
統計系 STAT,經濟學（一）,高
統計系 STAT,線性代數,高
統計系 STAT,程式設計,高
統計系 STAT,會計學（二）,高
```

```
科目名稱,已選人數,剩餘名額
統計學（一）,78,0
微積分（一）,61,0
線性代數,70,0
經濟學（一）,76,0
管理學,73,0
程式設計,68,0
機率概論,74,0
品質管制,20,0
會計學（一）,70,0
商事法,59,0
資料處理,59,0
資料庫概論,64,0
資料科學導論,118,122
數理統計（二）,80,0
實驗設計,87,0
無母數統計,72,0
工業統計,49,0
作業研究,55,0
衍生性商品,29,0
統計諮詢,31,0
統計資料分析,30,0
市場調查實務,12,0
統計問題,15,0
公司治理與財務報導-國際會計與稅務專題研,55,5
影像處理、電腦視覺及深度學習概論,214,85
```

Novelty

1、多模型集成與加權方法：我們採用了多模型集成策略，
結合了歷史數據的加權處理，提升了模型對近期數據變化的敏感性
，為預測的準確性提供了保障

2、使用加權平均方式，以及權重的標準化，對於有開設的課程進行預估
並評估準確度

3、優化的分類技術：透過分位數閾值與optuna參數優化的結合，
實現了靈活的熱門度分類，能有效應對不同課程的特性差異。

4、熱門課程的篩選：基於熱門度分析，每個系所熱門度課程清單被
成功生成，為各系提供不同的規劃參考

5、初步應用的方向性：我們的模型雖然初步使用了簡單的特徵值進行預測，但為未來的優化提供更清晰的方向，整合更多數據特徵，能夠顯著提升模型的應用價值

6、全流程自動化分析：從數據清理到結果輸出，我們構建了一個自動化預測與分類框架，顯著提升了實際應用的效率

7、寫了使用者介面利用課程特徵勾選的方式讓教授在開設新課前先預測這堂課的選課狀況

8、寫了使用者介面讓學生知道想學的東西可能在哪些課中學的到(相似度分析)

06

Future Directions

You can enter a subtitle here if you need it

1、寫出一個完整且功能完善的使用者介面

2、減少預測選課人數模型的數量及大小(可能將一些相似的課合併或是使用蒸餾算法之類的來節省模型)

3、使用更複雜的模型來進行訓練

4、利用一些方法提升模型的性能(調參數等等)

5、更加準確的課程特徵勾選以及考慮授課老師的因素等更多因素

07

The Contribution of each team member

You can enter a subtitle here if you need it

組員	貢獻
施淳譯	資料爬蟲、方法二;三實作、報告撰寫、簡報製作、報告
蔡譯穎	特徵勾選與預測方法實作、報告撰寫、簡報製作、報告
陳亭蓁	資料爬蟲、方法一實作、報告撰寫、簡報製作

Thanks!

CREDITS: This presentation template was created by **Slidesgo**, and includes icons by **Flaticon**, and infographics & images by **Freepik**

Please keep this slide for attribution